

Système de Reconnaissance Faciale pour la Détection de Criminels avec Réseau de neurones Convolutifs

Réalisé par : MOUSSA LASFAR
Encadré par : AZIZ KHAMJANE

Résumé: Les réseaux de neurones convolutifs (CNN) sont l'une des architectures les plus puissantes dans le domaine de l'apprentissage profond. Grâce à leurs performances exceptionnelles dans des domaines variés tels que la vision par ordinateur et le traitement du langage naturel, les CNN ont suscité un intérêt croissant dans l'industrie et la recherche académique ces dernières années. Ce projet se concentre sur l'application des CNN à la détection de criminels recherchés à partir de flux vidéo ou d'images.

Dans ce travail, nous proposons un modèle CNN entraîné sur un ensemble de données constitué de visages de criminels et de personnes non-criminelles. Nous utilisons cette approche pour identifier les criminels dans des vidéos ou des images statiques et déclencher une notification en cas de détection. Ce modèle repose sur des convolutions bidimensionnelles appliquées à des images en niveaux de gris, et nous explorons l'utilisation de différentes architectures CNN pour améliorer la précision et la vitesse du processus de détection.

Nous commençons par une brève introduction à l'histoire et à l'évolution des CNN. Ensuite, nous présentons l'architecture spécifique de notre modèle et les techniques de prétraitement des données. Après avoir détaillé

l'entraînement du modèle, nous discutons des résultats expérimentaux obtenus, en mettant en évidence les performances du modèle sur un ensemble de données de

test. Enfin, nous explorons les applications possibles de cette technologie dans les systèmes de vidéosurveillance, tout en discutant des limites actuelles et des perspectives futures pour cette approche.

1. Introduction

La sécurité publique est un enjeu majeur dans de nombreuses sociétés à travers le monde. La détection rapide des criminels recherchés est cruciale pour prévenir les infractions et assurer un environnement sûr. Cependant, dans les systèmes de sécurité traditionnels, la détection manuelle des criminels peut être lente et peu fiable. L'émergence des **réseaux de neurones convolutifs (CNN)** a révolutionné la vision par ordinateur et permis des avancées significatives dans des domaines comme la reconnaissance faciale, la détection d'objets, et la segmentation d'images.

Dans ce contexte, l'utilisation des CNN pour la détection de criminels à partir de vidéos ou d'images devient un atout majeur. Ce projet vise à développer un système automatisé de reconnaissance faciale qui permet d'identifier des individus à partir d'une **liste noire de criminels recherchés**. Le modèle, entraîné sur des données spécifiques, détecte les visages dans des flux vidéo en temps réel et émet une alerte en cas de détection d'un criminel.



figure 1: détection de criminel

L'objectif principal de ce projet est de créer une solution viable pour les forces de l'ordre, leur permettant d'intégrer cette technologie dans des systèmes de vidéosurveillance.

Cette technologie pourrait considérablement améliorer la réactivité et l'efficacité des interventions. Le modèle repose sur l'architecture d'un réseau de neurones convolutifs, spécialement conçu pour la reconnaissance faciale, et vise à offrir des résultats précis tout en étant rapide dans un environnement dynamique.




figure 2: pas de criminel détecte


Ainsi, ce travail s'inscrit dans un cadre innovant, combinant l'apprentissage automatique, la vision par ordinateur, et la sécurité publique. À travers ce projet, nous explorons comment les CNN peuvent être appliqués efficacement à des problèmes de sécurité en utilisant des méthodes de reconnaissance faciale pour automatiser la détection des criminels.

2. Données et Prétraitement


Pour constituer le jeu de données nécessaire à l'entraînement du modèle de reconnaissance faciale, les images ont été collectées à partir de sources accessibles en ligne, principalement à travers des recherches sur le Web et la plateforme Kaggle. Les images des criminels ciblés ont été soigneusement sélectionnées pour représenter une diversité de poses, d'éclairages et d'expressions faciales, afin de garantir la robustesse du modèle face à des variations réalistes.

division de données:

- données d'entraînement:



- données de validation:



Pour entraîner efficacement le modèle de reconnaissance faciale, des ensembles de données bien structurés ont été utilisés. Les données d'entraînement comprennent des images de visages de criminels figurant dans une liste noire ainsi que des visages non-criminels pour équilibrer le modèle et éviter des biais dans la prédiction. Un ensemble de données distinct a été réservé pour la validation, afin d'évaluer la performance du modèle sur des images non vues durant l'entraînement.



Avant d'être utilisées, les images ont été soumises à un prétraitement essentiel pour garantir leur compatibilité avec l'architecture du réseau de neurones convolutifs (CNN). Chaque image a été convertie en niveaux de gris afin de réduire la complexité computationnelle sans compromettre les caractéristiques importantes du visage. Ensuite, elles ont été redimensionnées à une taille uniforme de **100x100 pixels** pour


correspondre à l'entrée attendue du modèle. Enfin, les pixels ont été normalisés dans une plage de valeurs entre 0 et 1, ce qui accélère l'entraînement et améliore la convergence

en assurant une échelle homogène pour toutes les images.

La formule de normalisation:

$$X_{\text{norm}} = \frac{X - \min(X)}{\max(X) - \min(X)}$$

Ce prétraitement garantit que les données sont prêtes pour l'entraînement et permet au modèle d'extraire efficacement les caractéristiques pertinentes pour différencier les criminels des non-criminels.



3. Modèle Proposé

Le modèle proposé repose sur l'utilisation d'un **réseau de neurones convolutifs (CNN)**, une architecture largement reconnue pour ses performances en reconnaissance d'images.




figure 3: architecture de CNN

Il se compose de plusieurs couches convolutives pour extraire les caractéristiques importantes des visages, suivies de couches de pooling pour réduire la dimensionnalité tout en préservant les informations essentielles.

Ces couches permettent au modèle de capturer des caractéristiques à différents niveaux de complexité, allant des contours simples aux structures faciales plus complexes.

figure 3: couche convolutive





figure 4: couche de pooling



Après les couches convolutives et de pooling, le réseau se termine par des couches entièrement connectées (fully connected) qui convertissent les caractéristiques extraites en probabilités pour chaque classe (criminel ou non-criminel). La dernière couche utilise une activation **softmax**, adaptée pour les problèmes de classification multi-classes, afin de produire une probabilité pour chaque classe cible.

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^N e^{z_j}}$$

- z_i est la sortie de l'unité i (avant application de la fonction Softmax).
- N est le nombre total d'unités dans la couche de sortie.
- e^{z_i} est l'exponentielle de z_i
- La somme dans le dénominateur est effectuée sur toutes les unités de la

couche de sortie, ce qui garantit que la somme des sorties normalisées soit égale à 1.

Pour entraîner le modèle, nous utilisons une fonction de perte basée sur l'**entropie croisée catégorique**, qui est idéale pour les problèmes de classification. Cette fonction mesure la différence entre les distributions prédites et réelles, permettant ainsi au modèle d'ajuster ses paramètres pour minimiser cette divergence.

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^C y_{i,j} \cdot \log(\hat{y}_{i,j})$$

Explications :

- N : Nombre total d'exemples dans le lot d'entraînement (batch).
- C : Nombre de classes (par exemple, "criminel A", "criminel B", "non-criminel").
- $y_{i,j}$: Indicateur binaire qui vaut 1 si l'exemple i appartient à la classe j , sinon 0.
- $\hat{y}_{i,j}$: Probabilité prédite par le modèle pour que l'exemple i appartienne à la classe j .
- $\log$: Logarithme naturel, qui amplifie les erreurs pour les prédictions incorrectes.

Fonctionnement :

- Si la probabilité prédite $\hat{y}_{i,j}$ pour la classe correcte est proche de 1, la perte sera faible.
- Si $\hat{y}_{i,j}$ est faible pour la classe correcte, la perte sera élevée.

Cette fonction pénalise fortement les prédictions incorrectes et guide le modèle à ajuster ses paramètres pour améliorer la précision sur les données d'entraînement. Elle est particulièrement adaptée aux tâches de classification multi-classes avec softmax à la sortie.

4. Méthodologie

Le processus de détection des visages repose sur l'utilisation de l'algorithme **Cascade de Haar** pour localiser les visages dans les images avant l'étape de classification. Cet algorithme, basé sur des caractéristiques Haar, fonctionne en appliquant des filtres calculant des différences d'intensité entre régions claires et sombres dans une fenêtre glissante sur l'image. Ces caractéristiques sont ensuite combinées et organisées en cascades, permettant une détection rapide et efficace.

L'algorithme commence par détecter des régions potentielles en utilisant des filtres simples et peu coûteux, éliminant les zones peu probables dès les premières étapes. Les régions qui passent ces filtres sont ensuite traitées par des étapes successives plus complexes pour confirmer ou rejeter la présence d'un visage. Cette approche hiérarchique garantit une détection rapide et précise, même sur des images de tailles variées.

1. Fonctionnement de la méthode

Une petite fenêtre rectangulaire parcourt l'image.

Cette fenêtre analyse chaque partie de l'image pour vérifier si elle contient un visage.

Elle est redimensionnée pour détecter des visages de différentes tailles.




figure 5: extraction des caractéristiques

2. Les caractéristiques Haar (détecter des motifs faciaux)

Les caractéristiques Haar sont des motifs simples qui capturent des variations d'intensité (zones sombres et claires) typiques des visages humains.

Les yeux : Deux zones sombres sous une zone claire (front).

Le nez : Une zone sombre entre deux zones claires.

La bouche : Une bande sombre (lèvres) sous une zone claire (menton).




figure 6: caractéristiques Haar

Le processus d'entraînement du modèle a été soigneusement conçu pour optimiser les performances de classification. Afin de garantir une convergence stable, un taux d'apprentissage initial de **0,001** a été testé, avec un nombre d'époques fixé à **70** pour permettre un apprentissage approfondi et une taille de lot de **32** pour équilibrer l'efficacité de calcul et la mise à jour des poids. Une attention particulière a été portée à la gestion des classes déséquilibrées, en équilibrant les données des criminels avec celles de la classe "Not Criminal" par l'utilisation de techniques d'**augmentation de données** afin de réduire les biais du modèle.

Les hyperparamètres du modèle ont été optimisés à l'aide de **Keras Tuner**, qui a permis d'effectuer une recherche systématique pour déterminer les meilleures configurations. Les meilleurs hyperparamètres sélectionnés sont les suivants :

- **Filtres dans chaque couche convolutive** : 96 filtres pour les premières couches et 256 filtres pour les couches profondes, permettant au modèle d'extraire des caractéristiques

complexes et fines à chaque étape de l'entraînement.

- **Taille des noyaux** : **3x3** pour les trois premières couches et **5x5** pour la dernière, permettant une meilleure extraction des motifs à différentes échelles.
- **Taux de dropout de 0,4**, afin de réduire le surapprentissage et améliorer la capacité de généralisation du modèle.
- **Unité dans la couche dense** : **384 unités**, pour une meilleure capture des relations complexes entre les différentes caractéristiques extraites.
- **Taux d'apprentissage** : **0,001**, assurant un apprentissage progressif et stable.

Ce processus de recherche a permis de sélectionner les meilleurs hyperparamètres en fonction des performances sur les données de validation, assurant ainsi une meilleure généralisation et une réduction du surapprentissage, tout en optimisant la capacité du modèle à effectuer des prédictions sur de nouvelles données.




figure 7: variation de Accuracy et loss en fonction de epoch

Pour l'évaluation des performances, plusieurs métriques ont été utilisées. La précision a mesuré la proportion d'identifications correctes parmi toutes les prédictions, tandis que le rappel a évalué la capacité du modèle à identifier correctement toutes les instances positives. La F1-score, une moyenne harmonique entre la précision et le rappel, a été utilisée pour fournir une évaluation globale.





figure 8: matrice de confusion

De plus, une matrice de confusion a été générée après chaque phase d'entraînement pour visualiser les erreurs de classification et comprendre les confusions entre classes. Ces outils ont permis d'identifier les forces et les limites du modèle, guidant ainsi les ajustements des hyperparamètres et l'amélioration des données d'entraînement.

5. État de l'Art

La reconnaissance faciale est un domaine qui a connu une évolution rapide au fil des années grâce à l'émergence des techniques d'apprentissage automatique et des avancées en intelligence artificielle. À ses débuts, les systèmes de reconnaissance faciale utilisaient principalement des méthodes traditionnelles basées sur des descripteurs de caractéristiques comme **Eigenfaces** (1991) et **Fisherfaces** (1997). Ces approches, bien que novatrices, étaient limitées dans leur capacité à gérer les variations d'éclairage, d'angles et d'expressions faciales.



Avec l'avènement des **réseaux de neurones convolutifs (CNN)**, des modèles plus robustes ont été introduits. En 2014, **DeepFace** de Facebook a marqué une étape importante en atteignant un taux de précision proche des humains pour la reconnaissance faciale. D'autres modèles avancés, comme

FaceNet de Google (2015), ont introduit l'apprentissage d'embeddings pour comparer des visages avec une précision accrue. Ces technologies ont permis de déployer des applications dans des domaines variés, tels que la sécurité, l'e-commerce, et la biométrie.

Mon projet s'inscrit dans cette continuité tout en apportant des **contributions spécifiques** adaptées aux problématiques modernes, comme la détection en temps réel de criminels dans des flux vidéo. Contrairement à de nombreux modèles existants qui se concentrent uniquement sur l'identification, mon approche intègre des fonctionnalités pratiques :

1. **Notification en temps réel** : Lorsqu'un individu appartenant à une liste noire est détecté, le système envoie une alerte contenant son nom, une capture de son image et des informations de localisation. Cette fonctionnalité est cruciale pour des applications dans le domaine de la sécurité publique.
2. **Enregistrement dans une base de données (BDD)** : Toutes les détections sont enregistrées dans une base de données, incluant le nom de l'individu détecté, le timestamp, et une capture associée. Cette approche permet de centraliser et d'historiser les informations pour une consultation future, ce qui peut être utile pour les enquêtes ou la surveillance à long terme.
3. **Avantages spécifiques** : Mon modèle est conçu pour être intégré facilement dans des systèmes de vidéosurveillance existants, offrant une solution évolutive et modulaire. Il allie précision, rapidité de détection et des fonctionnalités pratiques qui répondent aux besoins des forces de l'ordre, des enquêteurs, ou des systèmes de sécurité privés.

En résumé, bien que des technologies avancées comme FaceNet et DeepFace aient posé les bases des systèmes de reconnaissance faciale modernes, ma contribution apporte une dimension

fonctionnelle et opérationnelle en combinant **détection en temps réel, alertes automatisées, et gestion centralisée des données**. Ces ajouts rendent le modèle particulièrement adapté aux enjeux actuels en matière de sécurité publique et de surveillance.

6. Discussion

Les résultats obtenus dans cette étude mettent en évidence plusieurs forces du modèle développé. L'utilisation des réseaux de neurones convolutifs (CNN) s'est avérée efficace pour extraire les caractéristiques faciales essentielles, garantissant une précision élevée sur les ensembles de test et de validation. Cette approche automatisée offre un avantage considérable en termes de rapidité et de fiabilité, minimisant le besoin d'une surveillance humaine constante. De plus, la conception modulaire et flexible du modèle permet son intégration dans une variété de systèmes, allant des caméras de surveillance aux applications mobiles.

Cependant, certaines limitations doivent être prises en compte. Les conditions défavorables, telles que les variations d'éclairage, les angles extrêmes ou les images de faible résolution, peuvent entraîner des faux positifs (identification erronée de non-criminels comme criminels) ou des faux négatifs (absence de détection d'un criminel).



figure 9: faible éclairage

De plus, un déséquilibre des données entre les différentes classes peut introduire des biais dans les prédictions.

Pour surmonter ces limites, plusieurs améliorations sont envisageables. L'augmentation des données, notamment par la génération d'images synthétiques ou l'application de transformations (rotation, zoom, ajustement de la luminosité), peut enrichir les classes et renforcer la robustesse du modèle. Par ailleurs, des ajustements précis des hyperparamètres, comme le taux d'apprentissage ou la taille des filtres convolutifs, peuvent optimiser la convergence. Enfin, l'exploration de modèles avancés tels que ResNet, EfficientNet ou Inception pourrait permettre une capture encore plus fine des caractéristiques faciales.

Ainsi, bien que le modèle actuel démontre une performance satisfaisante pour les tâches ciblées, il ouvre également la voie à des perspectives d'amélioration continue et à une adaptabilité accrue pour d'autres contextes.

7. Applications et Cas d'Utilisation

Le modèle développé offre une gamme d'applications pratiques dans divers domaines, en mettant particulièrement l'accent sur la sécurité publique. Intégré dans des systèmes de vidéosurveillance, il peut analyser les flux vidéo en temps réel pour identifier automatiquement les criminels figurant sur une liste noire et déclencher des alertes instantanées. Cette capacité permet une intervention rapide des forces de l'ordre, avec des informations clés telles que le nom du criminel, une capture d'image, et la localisation de la caméra à l'origine de la détection.

Au-delà de la sécurité publique, le modèle peut être utilisé dans des systèmes de contrôle d'accès biométrique pour autoriser uniquement les personnes habilitées à pénétrer dans des zones sensibles, telles que des installations militaires ou des centres de recherche. Il peut également jouer un rôle essentiel dans l'identification des personnes disparues, en comparant des visages capturés avec des bases de données existantes.

Dans des contextes commerciaux, ce système peut être employé pour personnaliser les expériences utilisateur. Par exemple, dans les magasins de détail, il pourrait analyser les

visages des clients pour proposer des offres ou des services adaptés à leurs préférences. Cette polyvalence démontre que le modèle n'est pas limité à la seule détection de criminels, mais peut s'étendre à une multitude de scénarios pratiques, combinant efficacité, flexibilité et utilité dans des secteurs variés.

8. Conclusion

En conclusion, ce projet démontre la puissance des réseaux de neurones convolutifs (CNN) pour la reconnaissance faciale et la détection automatique de criminels dans des images et des flux vidéo. Grâce à une architecture bien conçue et un ensemble de données structuré, le modèle a pu atteindre des performances satisfaisantes en termes de précision et de généralisation.

Les applications pratiques, telles que l'intégration dans des systèmes de vidéosurveillance et l'envoi de notifications en cas de détection, soulignent le potentiel de ce système pour renforcer la sécurité publique. Malgré certaines limitations, telles que les erreurs liées aux conditions de capture ou au déséquilibre des données, des pistes d'amélioration comme l'augmentation des données, l'ajustement des hyperparamètres et l'utilisation de modèles avancés offrent des perspectives prometteuses pour des systèmes encore plus robustes et polyvalents.

Ce projet met en lumière l'impact des technologies d'apprentissage profond dans des contextes réels, ouvrant la voie à de futures innovations dans le domaine de la sécurité et au-delà.

9. Références

Bibliothèque TensorFlow et Keras. Disponible sur : <https://www.tensorflow.org/>

- Framework utilisé pour développer et entraîner le modèle CNN.

Bibliothèque OpenCV. Disponible sur : <https://opencv.org/>

- Utilisée pour le traitement des images et la détection des visages.

Documentation de réseaux de neurones: <https://www.tensorflow.org/tutorials/images/cnn?hl=fr>

- Utilisée pour entraîner le model.

cascade haar documentation : https://docs.opencv.org/3.4/db/d28/tutorial_cascade_classifier.html

- Utilisée pour détecter les visages dans un flux de vidéo ou dans une image.